

Bases de données

L2 sciences et technologies, mention informatique

union et négation : requêtes relationnelles

ou : comment exprimer "lister les réalisateurs n'ayant pas réalisé un film chaque année" ?

films	titre	réalisateur	année	réalisateurs	nom	nationalité
	starwars	lucas	1977		lucas	américaine
	nikita	besson	1990		lynch	américaine
	locataires	ki-duk	2005		besson	française
	dune	lynch	1984		ki-duk	coréenne

patrick.marcel@univ-tours.fr

<http://celene.univ-tours.fr/course/view.php?id=3131>

plan de la séance

1. union

quels sont les films réalisés par "lynch" ou "ki-duk" ?

2. négation

quels sont les films qui ne sont pas réalisés par "besson" ?

existe-t-il des réalisateurs dans l'instance de "films" qui ne sont pas dans l'instance de "réalisateurs" ?

3. le cas particulier du calcul relationnel

union

union

quels sont les films réalisés par "lynch" ou "ki-duk" ?

en algèbre, on aimerait écrire :

$$\pi_{titre}(\sigma_{réalisateur="lynch"}(\text{films}) \cup \sigma_{réalisateur="ki-duk"}(\text{films}))$$

ou encore

$$\pi_{titre}(\sigma_{réalisateur="lynch" \vee réalisateur="ki-duk"}(\text{films}))$$

union

quels sont les films réalisés par “lynch” ou “ki-duk” ?

avec les règles, on aimerait écrire :

$\text{résultat}(t) \leftarrow \text{films}(t, \text{“lynch”}, a)$

$\text{résultat}(t) \leftarrow \text{films}(t, \text{“ki-duk”}, a)$

union

quels sont les films réalisés par “lynch” ou “ki-duk” ?

avec le calcul, on aimerait écrire :

$$\{t | \exists a_1, a_2, \text{films}(t, \text{"lynch"}, a_1) \vee \text{films}(t, \text{"ki-duk"}, a_2)\}$$

union et algèbre

opération \cup ajoutée à SPC

soit I_1 et I_2 deux instances de relations ayant même arité :

$$I_1 \cup I_2 = \{t \mid t \in I_1 \text{ ou } t \in I_2\}$$

on obtient l'algèbre SPCU

union et algèbre

opération \cup ajoutée à SPJR

I_1 et I_2 doivent avoir même sorte

on obtient l'algèbre SPJRU

union et algèbre

la sélection est généralisée aux formules disjonctives

les formes normales pour les requêtes sont définies comme suit :

une requête SPCU (resp., SPJRU) est sous forme normale si elle est l'union de deux requêtes SPC (resp., SPJR) sous forme normale

exemple

$$\pi_{titre}(\sigma_{réalisateur="lynch" \vee réalisateur="ki-duk"}(\text{films}))$$

n'est pas sous forme normale

$$\pi_{titre}(\sigma_{réalisateur="lynch"}(\text{films})) \cup \pi_{titre}(\sigma_{réalisateur="ki-duk"}(\text{films}))$$

est sous forme normale

union et langage de règles

on peut définir des ensembles de règles ayant le même nom de relation dans la tête

un programme *nr-datalog* sur un schéma R est un ensemble de n règles où

- ▶ il n'y a pas de nom de relation de R dans la tête
- ▶ il existe un ordre des règles de r_1 à r_n tel que
- ▶ le nom de relation dans la tête de r_i n'apparaît pas dans le corps de r_j si $j \leq i$

évaluation des programmes

soit I une instance de base de données et P un programme
nr-datalog

chaque règle est évaluée dans un ordre satisfaisant les critères
définis plus haut

l'union des faits est réalisée si 2 règles ont le même nom de
relation dans la tête

nr-datalog

le langage obtenu s'appelle *nr-datalog*

pourquoi “nr” ? pour *non*recursive

parce que ce genre de règle n'est pas autorisée :

$$\text{ancêtre}(x,z) \leftarrow \text{parent}(x,y), \text{ancêtre}(y,z).$$

exemple

soit le programme suivant :

$$r_1 \text{ résultat}(t) \leftarrow \text{films}(t, \text{" lynch"}, a)$$
$$r_2 \text{ résultat}(t) \leftarrow \text{films}(t, \text{" ki-duk"}, a)$$

on ordonne les règles dans l'ordre r_1, r_2 et on évalue les règles dans cet ordre

évaluation de r_1 { résultat(dune) }

évaluation de r_2 : { résultat(dune), résultat(locataires) }

union et calcul

le problème : on peut écrire $\{x,y | R(x) \vee R(y)\}$

c'est une requête syntaxiquement correcte, mais...

les variables x et y sont libres

donc la réponse est infinie !

les requêtes de ce type ne sont pas *sûres*

on règle ça tout à l'heure...

théorème

les langages suivants sont équivalents :

- ▶ l'algèbre SPCU
- ▶ l'algèbre SPJRU
- ▶ nr-datalog

ces langages expriment :

- ▶ les requêtes conjonctives avec union
- ▶ qui sont closes par composition

négation

en algèbre

quels sont les films qui ne sont pas réalisés par “besson” ?

$$\pi_{titre}(films - \sigma_{réalisateur="besson"}(films))$$

ou

$$\pi_{titre}(\sigma_{réalisateur \neq "besson"}(films))$$

en algèbre

existe-t-il des réalisateurs dans l'instance de "films" qui ne sont pas dans l'instance de "réalisateurs" ?

$$\pi_{réalisateur}(films) - \pi_{nom}(réalisateurs)$$

en langage de règles

quels sont les films qui ne sont pas réalisés par "besson" ?

$$ans(x) \leftarrow films(x,y,z), \neg films(x, "besson", z).$$

existe-t-il des réalisateurs dans l'instance de "films" qui ne sont pas dans l'instance de "réalisateurs" ?

$$réalisateursFilms(r) \leftarrow films(t,r,a)$$

$$réalisateursRéalisateurs(r) \leftarrow réalisateurs(r,n)$$

$$ans(x) \leftarrow réalisateursFilms(x), \neg réalisateursRéalisateurs(x)$$

algèbre

opérateur — défini sur des relations ayant même sorte (SPJRU) ou même arité (SPCU)

la sélection est généralisée pour permettre des formules autorisant la négation

$$\pi_{titre}(\sigma_{année=1990 \wedge réalisateur \neq "besson"}(films))$$

attention !

la différence ne peut pas être exprimée comme une jointure

exemple : soit $A = \{(1), (2)\}$ et $B = \{(1), (3)\}$

$$A - B \neq \pi_1(\sigma_{1 \neq 2}(A \times B))$$

algèbre relationnelle

le langage obtenu s'appelle l'*algèbre relationnelle*

ses propriétés :

- ▶ permet d'exprimer des requêtes non monotones
- ▶ permet d'exprimer des requêtes non satisfiables
- ▶ clos par composition

nr-datalog[¬]

nr-datalog[¬] : nr-datalog dans lequel des littéraux négatifs sont permis dans le corps des règles
une règle nr-datalog[¬] est de la forme :

$$q : S(u) \leftarrow L_1, \dots, L_n.$$

- ▶ S est un nom de relation
- ▶ S n'apparaît pas dans le corps de q
- ▶ u est un tuple libre
- ▶ les L_i sont des littéraux de la forme $R(v)$ ou $\neg R(v)$
 - ▶ R est un nom de relation
 - ▶ v un tuple libre

nr-datalog[¬]

$$q : S(u) \leftarrow L_1, \dots, L_n.$$

q est à champs restreint si chaque variable apparaît *au moins une fois dans un literal positif* de la forme $R(v)$ du corps

dans ce qui suit on considère uniquement des règles à champs restreint

exemple

$ans(x) \leftarrow films(x,y,z), \neg films(x, "besson", z).$

$ans(x) \leftarrow films(x,y,a), \neg réalisateurs(y, "américaine").$

sont à champs restreint

$ans(x) \leftarrow \neg films(x, "besson", z).$

$ans(y) \leftarrow films(x,y,z), \neg films(w,y, "1991").$

ne sont pas à champs restreint

nr-datalog[¬]

soient

- ▶ q une règle nr-datalog[¬] $S(u) \leftarrow L_1, \dots, L_n$.
- ▶ D un schéma de base de données qui inclut tous les noms de relation apparaissant dans le corps de q
- ▶ I une instance de D

l'image de I par q est :

$$q(I) = \{v(u) \mid v \text{ est une valuation et pour chaque } i \in [1, n], \\ v(u_i) \in I(R_i) \text{ si } L_i = R_i(u_i), v(u_i) \notin I(R_i) \text{ si } L_i = \neg R_i(u_i) \}$$

nr-datalog[¬]

un programme nr-datalog[¬] sur un schéma R est un ensemble de n règles nr-datalog[¬] tel que

- ▶ aucune relation de R apparaît dans la tête
- ▶ il existe un ordre r_1, \dots, r_n tel que le nom de relation dans la tête de r_i n'apparaît pas dans r_j si $i \geq j$.

exemple

$r_1 \text{ réalisateursFilms}(r) \leftarrow \text{films}(t,r,a)$

$r_2 \text{ réalisateursRéalisateurs}(r) \leftarrow \text{réalisateurs}(r,n)$

$r_3 \text{ ans}(x) \leftarrow \text{réalisateursFilms}(x), \neg \text{réalisateursRéalisateurs}(x)$

on ordonne les règles, par exemple dans l'ordre r_2, r_1, r_3

et on évalue selon cet ordre :

{ réalisateursFilms(lucas), réalisateursFilms(besson),
réalisateursFilms(ki-duk), réalisateursFilms(lynch),
réalisateursRéalisateurs(lucas), réalisateursRéalisateurs(besson),
réalisateursRéalisateurs(ki-duk), réalisateursRéalisateurs(lynch) }

théorème

l'algèbre relationnelle et les programmes nr-datalog^{\neg} ont la même puissance d'expression

Calcul relationnel

le calcul relationnel

on ajoute au calcul conjonctif :

- ▶ la négation \neg
- ▶ la disjonction \vee
- ▶ la quantification universelle \forall

remarque

si φ et ψ sont deux formules :

$$\varphi \vee \psi \quad \equiv \quad \neg(\neg\varphi \wedge \neg\psi)$$

$$\forall x\varphi \quad \equiv \quad \neg\exists x\neg\varphi$$

exemple

Soit la relation $vu[\text{spectateur, titre}]$

$$\forall s, vu(s, "starwars") \equiv \neg \exists s \neg vu(s, "starwars")$$

syntaxe

soit D un schéma de base de données, $e, e' \in \mathbf{dom} \cup \mathbf{var}$

les formules du *calcul relationnel* sont :

1. un atome sur D
2. $e = e'$ ou $e \neq e'$
3. $\varphi \wedge \psi$ où φ et ψ sont des formules
4. $\varphi \vee \psi$ où φ et ψ sont des formules
5. $\neg\varphi$ où φ est une formule
6. $\exists x\varphi$ où φ est une formule
7. $\forall x\varphi$ où φ est une formule

syntaxe

on utilisera les abréviations suivantes :

$$\varphi \rightarrow \psi \quad \equiv \quad \neg \varphi \vee \psi$$

$$\varphi \leftrightarrow \psi \quad \equiv \quad (\varphi \wedge \psi) \vee (\neg \varphi \wedge \neg \psi)$$

variable libre/liée

$free(f)$ est l'ensemble des variables libres de f

- ▶ si R est un atome, $free(R) = var(R)$
- ▶ $free(e = e') = free(e \neq e') = \{e, e'\}$
- ▶ $free(\varphi \wedge \psi) = free(\varphi) \cup free(\psi)$
- ▶ $free(\varphi \vee \psi) = free(\varphi) \cup free(\psi)$
- ▶ $free(\neg \varphi) = free(\varphi)$
- ▶ $free(\exists x \varphi) = free(\varphi) - \{x\}$
- ▶ $free(\forall x \varphi) = free(\varphi) - \{x\}$

un variable non libre est une variable *liée*

exemple

dans la formule φ suivante

$$\forall z \exists y, \textit{films}(y, x, z)$$

$$\textit{free}(\varphi) = \{x\}$$

requêtes

une requête du calcul relationnel est une expression de la forme

$$\{e_1, \dots, e_n | \varphi\}$$

où φ est une formule du calcul relationnel, et les variables de (e_1, \dots, e_n) sont exactement $free(\varphi)$

exemple

“quels sont les films sortis en 2005 dont le réalisateur n'est pas américain”

$$\{t | \exists r, \text{films}(t, r, "2005") \wedge \neg \text{réaliseurs}(r, "américaine")\}$$

“quelles sont les nationalités des réalisateurs ayant sorti un film uniquement en 2000?”

$$\{n | \exists r, \text{réaliseurs}(r, n) \wedge \exists t \text{films}(t, r, 2000) \wedge \neg(\exists a, t' (\text{films}(t', r, a) \wedge a \neq 2000))\}$$

les problèmes (1)

$$q = \{x | \neg \text{films}(x, "lucas", "1977")\}$$

ou

$$q = \{x, y | \text{films}(x, "lucas", "1977") \vee \text{films}("starwars", "lucas", y)\}$$

$q(I)$ infinie quelle que soit I ...

car x et y prennent leurs valeurs dans **dom**, qui est infini !

donc il existe une infinité de valeurs possibles pour x et y qui satisfont ces expressions

exemple

$$q = \{x \mid \neg \text{films}(x, \text{" lucas" }, \text{" 1977" })\}$$

$$I(\text{films}) = \{\text{films}(\text{starwars}, \text{lucas}, 1977)\}$$

$$q(I) = \{ET, 2001, Dune, \dots\}$$

solutions

1. les variables prennent leurs valeurs dans $adom(q, I)$
ou
2. interdire (syntaxiquement) les requêtes non sûre

on étudiera la première solution, le langage CAL_{adom}

les problèmes (2)

$$q = \{x | \forall y, R(x, y)\}$$

si y prend ses valeurs sur **dom**, $q(I) = \emptyset$ quelle que soit I

si y prend ses valeurs sur un ensemble fini, $q(I)$ peut être non vide

cette requête est dépendante du domaine sur lequel elle est interprétée

exemple

Soit la relation $vu[\text{spectateur}, \text{titre}]$

$$q = \{t \mid \forall s, vu(s, t)\}$$

$$I(vu) = \{vu(s1, t1), vu(s2, t1), vu(s1, t2)\}$$

si s prend ses valeurs sur $\{s1\}$ alors $q(I) = \{t1, t2\}$

si s prend ses valeurs sur $\{s1, s2\}$ alors $q(I) = \{t1\}$

si s prend ses valeurs sur $\{s1, s2, s3\}$ alors $q(I) = \emptyset$

solutions

- ▶ fixer le domaine d'interprétation
ou
- ▶ interdire (syntactiquement) ce type de requêtes

on étudiera la première solution, le domaine d'interprétation est fixé à $adom(q, I)$

sémantique domaine actif

$q = \{e_1, \dots, e_n | \varphi\}$ une requête et I une instance

on se restreint aux valuations de $free(\varphi)$ dans $adom(q, I)$

dans la suite :

- ▶ v est une valuation satisfaisant cette restriction
- ▶ on note $adom = adom(q, I)$

sémantique domaine actif

I satisfait φ pour v relativement à $adom(q, I)$, noté $I \models_{adom} \varphi[v]$ si

1. $\varphi = R(u)$ est un atome et $v(u) \in I(R)$
2. $\varphi = (s = s')$ où $s, s' \in \mathbf{dom} \cup \mathbf{var}$ et $v(s) = v(s')$
3. $\varphi = (\psi \wedge \xi)$ et $I \models_{adom} \psi[v|_{free(\psi)}]$ et $I \models_{adom} \xi[v|_{free(\xi)}]$
4. $\varphi = (\psi \vee \xi)$ et $I \models_{adom} \psi[v|_{free(\psi)}]$ ou $I \models_{adom} \xi[v|_{free(\xi)}]$
5. $\varphi = \neg\psi$ et $I \not\models_{adom} \psi[v]$
6. $\varphi = \exists x \psi$ et il existe $c \in adom$, $I \models_{adom} \psi[v \cup \{x/c\}]$
7. $\varphi = \forall x \psi$ et pour tout $c \in adom$, $I \models_{adom} \psi[v \cup \{x/c\}]$

image d'une requête

soit D un schéma de base de données, $q = \{e_1, \dots, e_n | \varphi\}$ une requête sur D , et I une instance de D

l'image de I par q , notée $q(I)$, est :

$$q(I) = \{v((e_1, \dots, e_n)) | I \models_{\text{adom}} \varphi[v] \text{ et} \\ v \text{ est une valuation sur } \text{free}(\varphi) \\ \text{dont l'image} \subseteq \text{adom}(q, I)\}$$

exemple

soit l'instance I :

$$I(films) = \{films(starwars, lucas, 1977)\}$$

$$I(vu) = \{vu(s1, t1), vu(s2, t1), vu(s1, t2)\}$$

et les requêtes :

$$q_1 = \{x \mid \neg films(x, "lucas", "1977")\}$$

$$q_2 = \{t \mid \forall s, vu(s, t)\}$$

$$adom = \{starwars, lucas, 1977, s1, s2, t1, t2\}$$

$$q_1(I) = \{lucas, 1977, s1, s2, t1, t2\}$$

$$q_2(I) = \emptyset$$

théorème

les langages suivants sont équivalents :

- ▶ algèbre relationnelle
- ▶ nr-datalog[¬]
- ▶ $\text{CALC}_{\text{adom}}$